



Document Management using Protégé

Henrik Eriksson
Linköping University



Approach: Semantic Documents

- Combine documents with knowledge representation
 - Like semantic web, but for “real” documents
- Semantic Documents
 - Printable electronic documents
 - Knowledge representation: Ontologies, workflows, and rules
 - An integrated format that keeps textual and computer-based guidelines together
 - Based on wide-spread document formats
- Currently supported format: PDF

Just det att hundra
får marken själv
dingarna med sig
den palttröden
det finns en lada
och det finns en
som blanda riefel
a mason

ECKEN
ENINGA
OBJEKT

MÖBELDESIGN

words
QUIS AHAT DÉCAT!!
Nor juinde

edford's daughter

Y * T N T *
Y * N AVEZ - VOUS
Y *

zenni skö
ften vad hon
er vad hon



- Rättsteorin och
- Attvärde
- Offentlig rätt
- Attvärde, stads

OnLib
www.lib.se

92: 9
Br
A 6
Zf =

FRANKFURTER UNIVERSITÄT
FRIEDRICH-SCHLEGEL-STRASSE 1
D-60325 FRANKFURT AM MAIN
TEL: +49 (0) 69 79 10 1
FAX: +49 (0) 69 79 10 2
E-MAIL: info@frankfurt-universitaet.de

- Just det att hundra
får marken själv
dingarna med sig
den palttröden
det finns en lada
och det finns en
som blanda riefel
a mason
- ECKEN
ENINGA
OBJEKT
- MÖBELDESIGN
- words
QUIS AHAT DÉCAT!!
Nor juinde
- edford's daughter
- Y * T N T *
Y * N AVEZ - VOUS
Y *
- zenni skö
ften vad hon
er vad hon
- Rättsteorin och
- Attvärde
- Offentlig rätt
- Attvärde, stads
- OnLib
www.lib.se
- 92: 9
Br
A 6
Zf =
- FRANKFURTER UNIVERSITÄT
FRIEDRICH-SCHLEGEL-STRASSE 1
D-60325 FRANKFURT AM MAIN
TEL: +49 (0) 69 79 10 1
FAX: +49 (0) 69 79 10 2
E-MAIL: info@frankfurt-universitaet.de



Just det att hundra
får marken själ-
dingarna med sig
den palttröden
det finns en lada
och det finns m-
som blanda riefel
ECKEN
ENINGA
OBJEKT
MÖBELDESIGN
words
QUIS AHAT DÉCAT!!
Rör ju inte
edford's daughter
DY * DNF *
R * DN Auez-uus
F *
människa ej
ften vad hon
er vad hon
- Rättsteorin och r
- Att är rätt
- Att är rätt
- Att är rätt, stads
OnLib
www.lib.se
92: 9
Br
LUND UNIVERSITY
LUND UNIVERSITY
Zf =

PDFTab: Annotation Tool for Protégé

Annotation tool

Protégé

Adobe Acrobat
(PDF)

yearbook Protégé 3.1 (file: C:\cygwin\home\ther\Annotator\yearbook.pprj; OWL Files (.owl or .rdf))

File Edit Project OWL Code Window Document Utilities Tools Help

OWLClasses Properties Forms Individuals Metadata Documents

DOCUMENT BROWSER

For Project: yearbook

Documents

yearbook2005.pdf

DOCUMENT ANNOTATOR

For Document: yearbook2005.pdf

Meta view Annotations view Targets view PDF view

Save a Copy Search Select 115% Sign

Options

Bookmarks

Pages

Attachments

Comments

Förord
Teckenförklaring
Kvalitetsdeklaration
Innehåll
Kartor
Geografiska uppgifter
Miljö och väder
Befolkning
Jordbruk, skogsbruk och fiske
Näringsverksamhet
Energi
Boende, byggnad och bebyggelse
Handel med varor och tjänster
Transporter och kommunikation
Informations och kommunikation
Arbetsmarknad
Hushållens ekonomi
Priser och konsumtion
Nationalräkenskaper
Offentlig ekonomi
Finansmarknad
Socialförsäkring
Socialtjänst
Hälsa och sjukvård
Rättssystem
Utbildning och forskning
Kultur och fritid
Medborgarinflytande
Tio-topp
Internationella översikter

72 Areal och folkmängd i tätorter den 31 december 2000, länsvis
Population of localities, by county


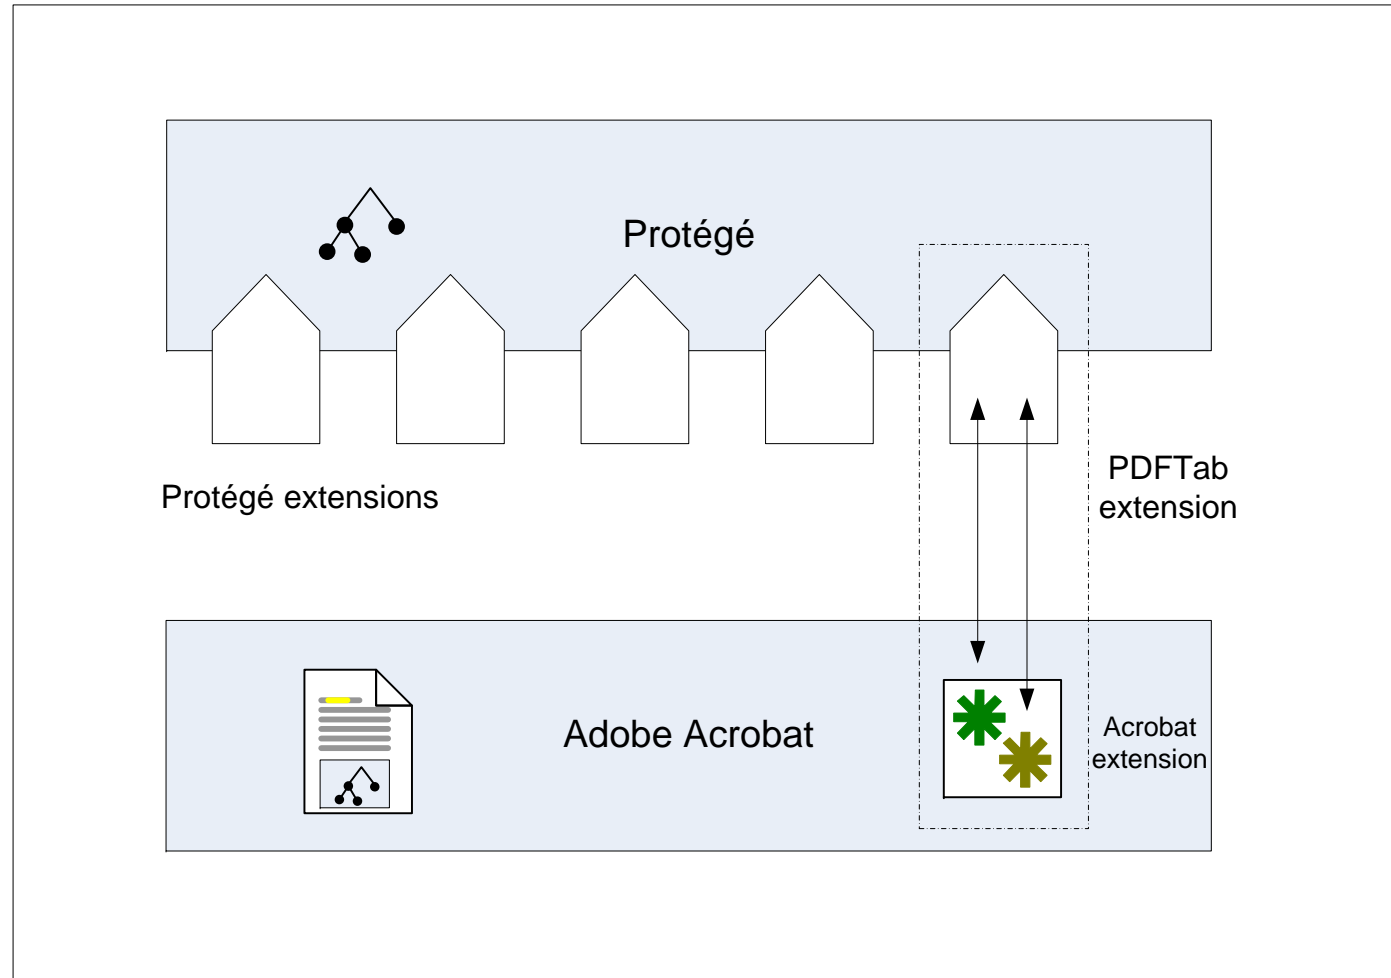
Län County	Tätorternas landareal, hektar ¹	Antal tätorter ² med ... invånare Number of localities ² with ... inhabitants				Summa tätorter Total
		200- 499	500- 1 999	2 000- 9 999	10 000- 49 999	
Stockholms	68 312	40	28	25	10	68 418
Uppsala	14 372	19	22	11	2	14 427
Södermanlands	14 564	19	26	12	4	14 626
Östergötlands	21 665	44	19	21	3	21 754
Jönköpings	21 665	37	30	16	5	21 744
Kronobergs	12 565	16	26	9	1	12 618
Kalmar	18 329	42	39	10	—	—
Gotlands	3 293	9	7	—	—	—
Blekinge	10 976	20	15	7	—	—
Skåne	56 651	82	97	54	—	—
Hallands	18 328	36	42	13	—	—
Västra Götalands	79 341	120	124	50	—	—
Värmlands	20 068	32	21	15	—	—
Örebro	20 065	21	28	11	—	—
Västmanlands	16 855	14	16	10	—	—
Dalarnas	30 621	47	47	10	—	—
Gävleborgs	22 734	42	28	12	—	—
Västernorrlands	20 039	33	30	11	—	—
Jämtlands	9 619	27	23	4	—	—
Västerbottens	17 045	30	19	20	—	—
Norrbottens	23 939	50	25	15	—	—
Hela riket Sweden	521 038	780	712	336	88	1 936

Län	Summa folkmängd i tätorter ² med ... invånare Population in localities ² with ... inhabitants				Folkmängd i tätorter ² Inhabitants in localities ²	Folkmängd i tätorter ² i procent av hela folkmängden ²
	200- 499	500- 1 999	2 000- 9 999	10 000- 49 999		
Stockholms	12 880	25 344	136 757	235 284	1 739 637	95,4
Uppsala	5 938	23 627	50 597	32 038	124 036	80,3
Södermanlands	6 233	24 285	48 983	71 183	208 551	81,5
Östergötlands	14 357	15 743	81 943	54 760	176 992	83,6
Jönköpings	11 628	33 428	72 283	71 024	269 735	82,3
Kronobergs	4 732	27 170	35 494	14 485	133 671	75,7
Kalmar	13 171	39 274	45 115	84 086	181 626	77,2
Gotlands	2 644	8 076	—	22 017	32 737	57,1
Blekinge	6 662	15 909	32 912	62 326	117 809	78,3
Skåne	25 251	97 715	271 823	182 209	987 272	87,4
Hallands	12 561	41 035	46 825	60 780	214 688	78,1
Västra Götalands	39 252	119 874	233 935	290 098	1 240 937	83,0
Värmlands	9 125	20 121	71 878	44 498	202 102	73,5

80 of 784

C:\cygwin\home\ther\Annotator\yearbook2005.pdf

Tool Architecture



Corresponding Ontology

The screenshot displays the Protégé 3.0 beta ontology editor interface. The main window is titled "test1 Protégé 3.0 beta" and shows the following components:

- CLASS BROWSER:** Displays the class hierarchy for the project "test1". The selected class is "Tabell" (10 instances). The hierarchy includes:
 - owl:Thing
 - DocumentReference (1)
 - Dokumentdel
 - Diagram (3)
 - KommentarDiagram (4)
 - FaktaOmStatistiken (1)
 - Innehållsförteckning (2)
 - Karta (1)
 - ListOfTerms (1)
 - Sammanfattning (2)
 - Statistikkommentar (14)
 - Tabell (10)
 - KommentarTabell (5)
 - Titel (1)
 - PDFAnnotation
 - PDFGraphicsAnnotation
 - PDFRectAnnotation
 - PDFTextAnnotation (44)
 - PDFDocument (1)
 - TableColumn (108)
 - TableColumnGroup (26)
 - macro:Område
 - macro:Storhet
 - rdf:Property (12)
- INSTANCE BROWSER:** Lists instances for the selected class "Tabell". The list includes:
 - 1. Befolkningsförändringar 1994-2003
 - 10. Utrikes födda och utländska medborgare i lä...
 - 2. Immigranter och emigranter efter medborgarsk...
 - 3. Immigranter och emigranter efter födelseländ...
 - 4. Länens folkmängd 31 december 2000, 2001, 2002...
 - 5. Länens folkmängd 31 december 2003 och befolk...
 - 6. Kommunernas folkmängd 31 december 2003
 - 7. Kommunerna i storleksordning efter antal inv...
 - 8. Folkmängden 31 dec. 1997 - 2003 samt befolk...
 - 9. Folkmängden efter kön och ålder 31 decemb...
- INSTANCE EDITOR:** Shows the details for the selected instance "5. Länens folkmängd 31 december 2003 och befolk...". The editor includes:
 - Name:** test1_Individual_15
 - RDFS:COMMENT:** (empty text area)
 - NUMMER:** 5
 - TEXT:** Länens folkmängd 31 december 2003 och befolkningsförändringar 2003
 - REFERENCE:** Länens folkmängd 31 december 2003 och befolk...
 - COLUMNS:** 2 Folkmängd, 3 Levande födda, 3 Folkökning, 1 Län

Document Mark Up

Window Tools Document Utilities Help

BE0101_2003M12_SM_BE12SM0401x1e.pdf

Forms Individuals Metadata Documents

DOCUMENT ANNOTATOR

For Document: BE0101_2003M12_SM_BE12SM0401x1e.pdf

Meta view PDF view

BE0101_2003M12_SM_BE12SM0401x1e.pdf

Save a Copy

Pages

SCB 22

7. Kommunerna i storleksordning efter antal invånare 1 januari 2004

7. Municipalities by size of population on Dec. 31, subdivisions of Jan. 1, 2004

Kommunerna i storleksordning	Folkmängd	Antal		Kommunerna i storleksordning
1 Stockholm	761 721	3 573		57 År
2 Göteborg	478 055	3 134	0,66	58 U
3 Malmö	267 171	1 690	0,64	59 Li
4 Uppsala	180 669	996	0,55	60 V
5 Linköping	136 231	1 165	0,86	

INDIVIDUAL EDITOR

FOR INDIVIDUAL: 7. Kommunerna i storleksordning efter antal invånare 31 december 2003 enligt indelning 1 januari 2004 (type=Tabell, name=test1_Individual_17)

Name SameAs DifferentFrom

test1_Individual_17

RDFS:COMMENT:

NUMBER: 7 TEXT: Kommunerna i storleksordning efter antal invånare 31 december 2003 enligt indelning 1 januari 2004


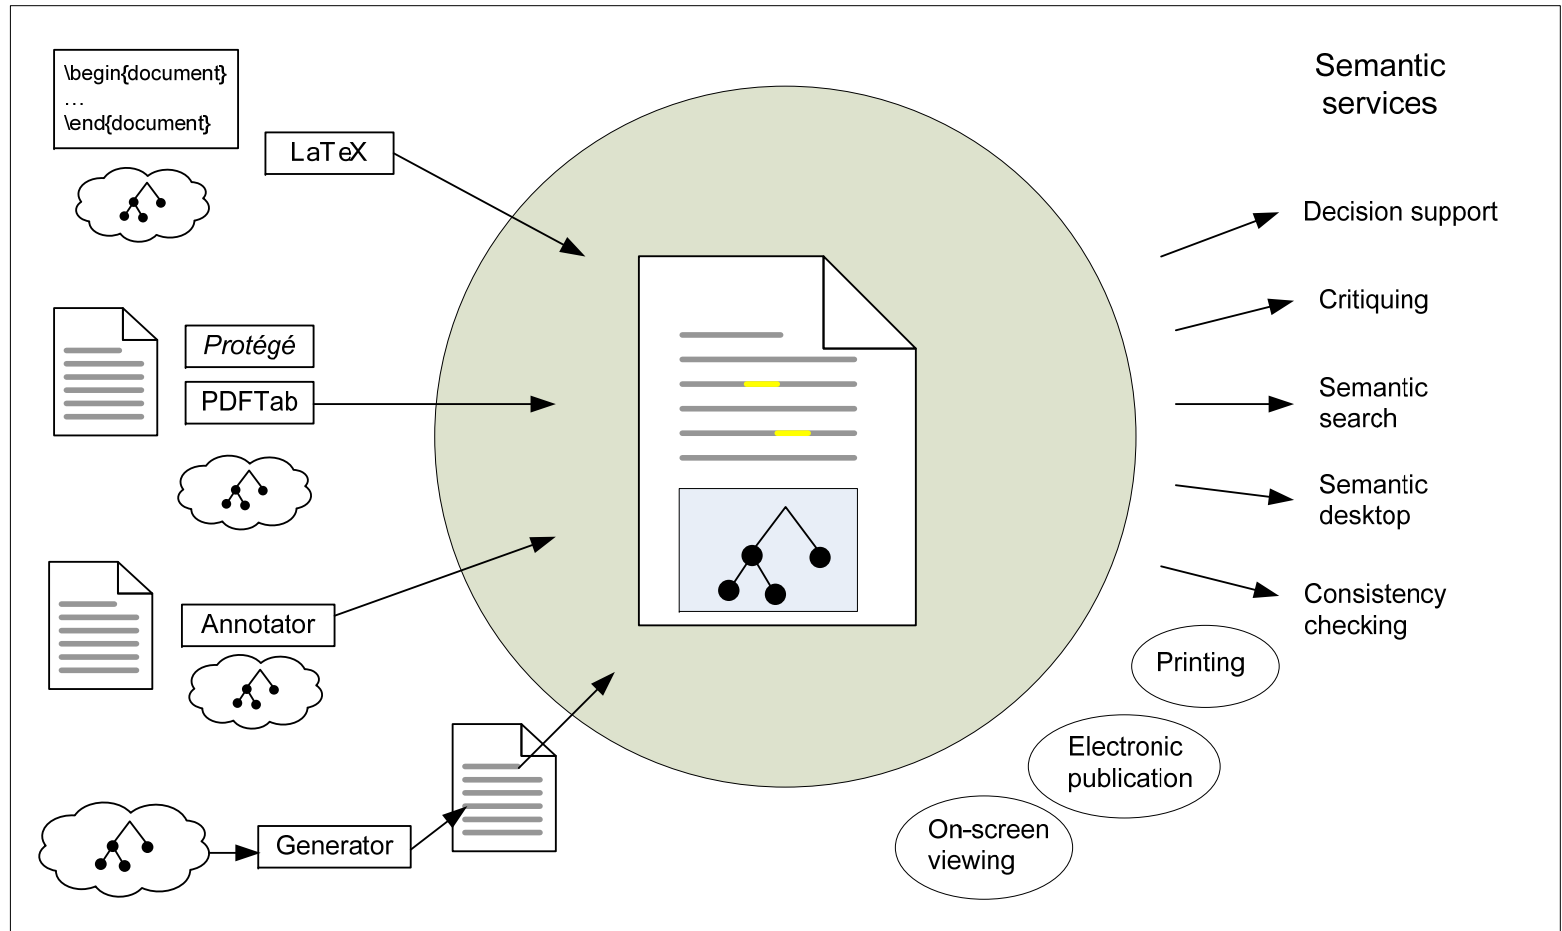
REFERENCE: 7. Kommunerna i storleksordning efter antal invånare 31 december 2003 enligt

COLUMNS: 3 Folkmängd 2 Kommunerna i storleksordning 1 Kommunerna i storleksordning

Just det att hundra
får marken själ-
dingarna med sig
den palttröden
det finns en lada
och det finns m-
som blanda riefel
ECKEN
ENINGA
OBJEKT
MÖBELDESIGN
words
QUIS AHAT DÉCAT!!
Rör ju inte
edford's daughter
DY * DNF *
R * DN Auez-uus
F *
människa ej
ften vad hon
er vad hon
- Rättsteorin och r
- Att är rätt
- Att är rätt
- Att är rätt, stads
OnLib
www.lib.se
92: 9
Br
LUND UNIVERSITY
LUND UNIVERSITY
Zf =

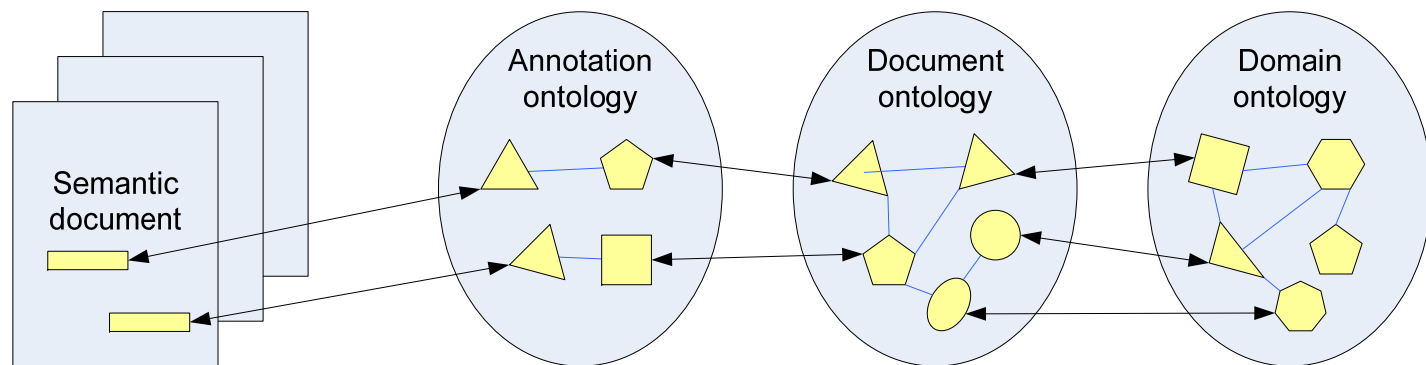


Document-centric Annotation Framework



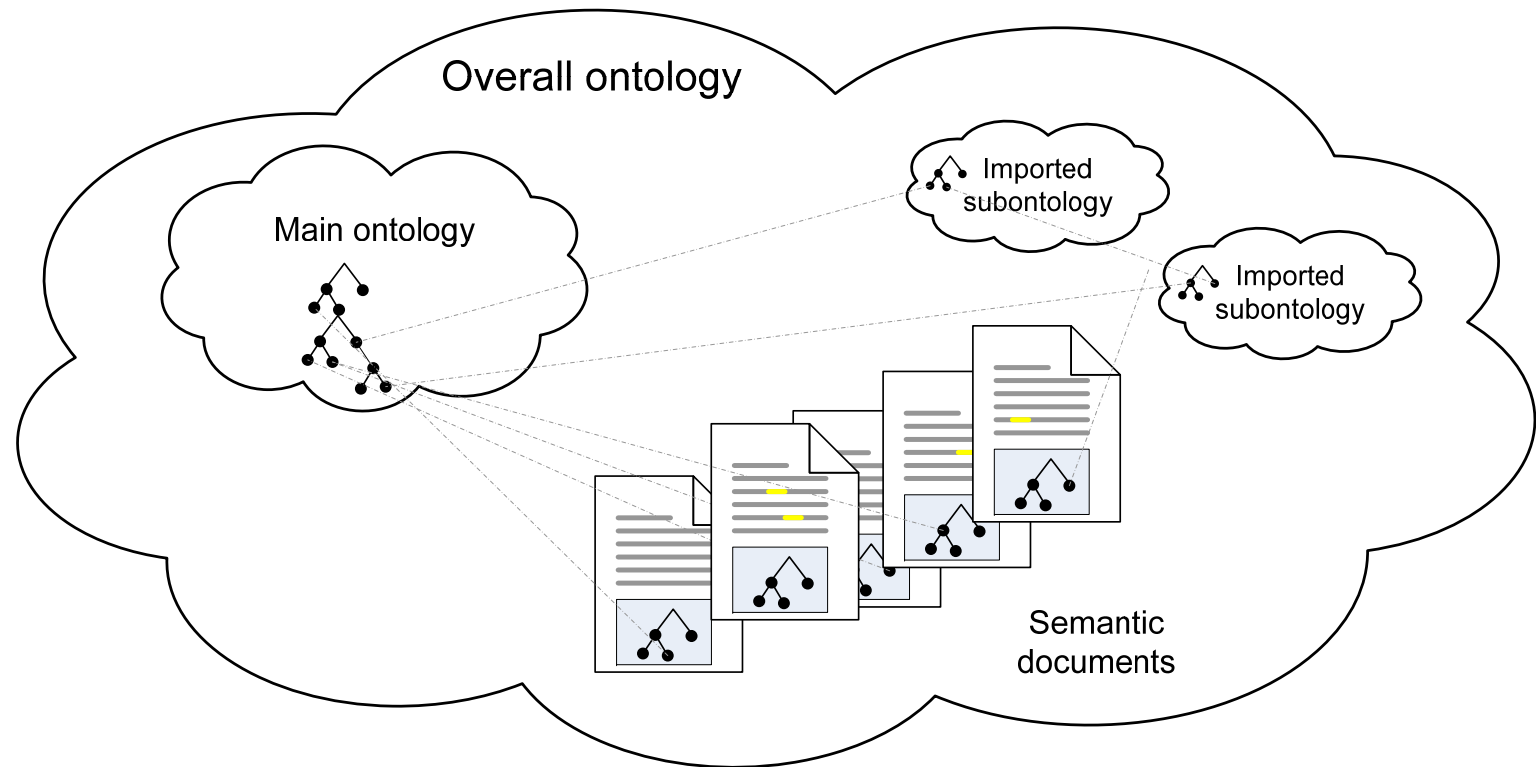
Ontology Structure


- Linking documents and ontologies
- Standard ontology structure
 - Annotation ontology
 - The annotation types
 - Document ontology
 - The key document parts
 - Domain ontology
 - The “regular” ontology



Supporting multiple documents

- Architecture with multiple ontologies and ontology modules





Case Study: Document Repository in Protégé

- Document data set
 - All statistics reports (PDF) published by Statistics Sweden in 2006
 - Five volumes of Statistical Yearbook (2002–2006)
- Method
 - Document acquisition
 - Ontology development
 - Automated annotation (through annotator program)
- Number of automatically-annotated documents: 302
- Total number of annotations for these documents: 17,470

Statistics Reports Loaded in Protégé

SCB Protégé 3.3 beta (file:\C:\cygwin\home\her\Annotator\SCB.pprj, OWL / RDF Files)

File Edit Project OWL Code Tools Window Document Utilities Help

OWLClasses Properties Forms Individuals Metadata (unnamed.owl) Documents Document Search

DOCUMENT BROWSER

For Project: SCB

Documents

- AM0102_2006M04_SM_AM17SM0606_annot.pdf
- PR0301_2006M02_SM_PR10SM0603_annot.pdf
- NV0109_2005A01A_SM_NV19SM0602_annot.pdf
- HA0201_2006M07S_SM_HA17SM0607_annot.pdf
- HA0201_2006M03D_SM_HA22SM0601_annot.pdf
- JO0601_2006A01_SM_JO19SM0601_annot.pdf
- OV0904_1750I04_BR_A01SA0501_annot.pdf
- MI0504_2004A01_SM_MI45SM0601_annot.pdf
- NV1701_2006M03_SM_NV41SM0606_annot.pdf
- AM0301_2006M06_SM_AM39SM0608_annot.pdf
- NV1701_2006M06_SM_NV41SM0609_annot.pdf
- JO0904_1994I05_SM_JO45SM0602_annot.pdf
- ME0201_2006M05_SM_ME60SM0601_annot.pdf
- JO0701_2006M03_SM_JO48SM0605_annot.pdf
- JO0202_2005A01_SM_JO33SM0601_annot.pdf
- PR0101_2006M01_SM_PR14SM0602_annot.pdf
- JO1101_2006M07_SM_JO50SM0608_annot.pdf
- PR0101_1830I05_SM_PR15SM0601_annot.pdf
- JO1101_2006M04_SM_JO50SM0605_annot.pdf
- AM0206_2006K03_SM_AM61SM0604_annot.pdf
- JO1101_2006M05_SM_JO50SM0606_annot.pdf
- EN0113_2004A02_SM_EN23SM0601_annot.pdf
- JO0904_2005I06_SM_JO45SM0603_annot.pdf
- PR0101_2006M03D_SM_PR14SM0604_annot.pdf
- JO0701_2005M12_SM_JO48SM0602_annot.pdf
- FM0201_2006H01_SM_FM20SM0602_annot.pdf
- AM0101_2006M03_SM_AM38SM0605_annot.pdf
- JO0901_2004A01_SM_JO40SM0601_annot.pdf

DOCUMENT ANNOTATOR

For Document: ME0201_2006M05_SM_ME60SM0601_annot.pdf

Meta view Annotations view Targets view PDF view

AM0301_2006M06_SM_AM39SM0608_annot.pdf ME0201_2006M05_SM_ME60SM0601_annot.pdf

83%

1. Arbetskostnadsindex för arbetare inom privat sektor
1. Labour cost index for wage-earners in the private sector

Näringsgren	Juni 2006	Förändring från juni 2005, % ²	
SNI		prel/def	prel/prel
C+D+E	158,1	3,6	4,0
F	163,0	3,4	3,1
G+H	160,8	3,1	3,2
I	155,5	3,7	3,8
J+K	152,0	1,0	0,9
M+N+O	148,5	3,7	4,2
C-O	157,1	3,1	3,2


1) 1:a kvartalet 1994=100
2) Förändringstalen beräknas på indextal med fler än en decimal.
1) 1st kvartal 1994=100
2) The calculation of percentage changes includes several decimals

2. Arbetskostnadsindex för tjänstemän inom privat sektor
2. Labour cost index for salaried employees in the private sector

Näringsgren	Juni 2006	Förändring från juni 2005, % ²	
SNI		prel/def	prel/prel
C+D+E	179,9	1,7	2,3
D	179,8	1,7	2,4
28-35	181,3	1,6	2,4
F	171,9	2,6	3,7
G+H	169,5	2,6	3,2


5 of 19

C:\cygwin\home\her\SCB-doc\pub\ME0201_2006M05_SM_ME60SM0601_annot.pdf



Discussion

- Scalability issues
 - Beyond hundreds of documents
 - Too many ontologies for the current Protégé implementation
 - How can we scale to thousands or millions of documents
- Vision: Repository storage backend
 - Possibly backend based on a document-repository database (e.g., Dspace)
 - Normal document services and semantic services



Summary

- Semantic Documents
- Protégé — a platform for document management
- Ontologies as model document repositories
- Furthermore, ontologies can act as document repositories
- However, large document sets will require a custom-tailored database backend